


學號：R08922167 系級：資工碩一 姓名：曾民君

1. (2%) 從作業三可以發現，使用 CNN 的確有些好處，試繪出其 saliency maps，觀察模型在做 classification 時，是 focus 在圖片的哪些部份？

答：在經過觀察多張影像後發現，會發現有極大部分的擺盤、餐桌的桌巾或是裝食物的包裝紙的顏色都偏向白色/乳白色。而這些區域經過 model 訓練之後，似乎會將白色的擺盤、桌巾或是包裝等等的區域視為不重要的資訊，如下圖中右邊三張影像，食物本身有不少 pixel 是被 model 視為重要的部份，但周遭白色餐具部份就比較沒有。









但擺盤的顏色是偏離白色範圍的話，有機會被 model 認為是重要資訊，如下圖最右邊影像，就是一個相當極端的例子，擺盤顏色跟食物本身顏色相距不大，造成 model 幾乎視擺盤跟食物本身的重要性相當。



2. (3%) 承(1) 利用上課所提到的 gradient ascent 方法，觀察特定層的 filter 最容易被哪種圖片 activate 與觀察 filter 的 output。(Collaborators:)

答：這邊我的 model 主要是由 5 層 cnn layer_block 組成，而此次觀察目標為第二層 cnn layer 的第 64 個 filter (此層的 filter 數為 64)，這一層的 filter 所能夠取得的資訊還算是比較小區域的資訊，而在這個 filter 對於上題提到的白色區域 (碗盤、桌巾、餐巾紙、食物包裝 等等) 輸出的值算是相當的大。[黑(低) -> 白(高)] 如下圖所有影像中的白色餐具，都擁有蠻高的輸出值。


食物部份，湯類別的食物與荷包蛋的食物本體部份，可能是顏色是比較接近白色，或是說顏色比較淡，他們經過這層 cnn 輸出的值是相對其他類別的分數較高。另一方面，漢堡肉與麵食類的食物本體部份，可能顏色是比較黯淡的區域所以導致這些食物本體經過這層 cnn 的輸出相對其他食物還要來的低。



3. (2%) 請使用 Lime 套件分析你的模型對於各種食物的判斷方式，並解釋為何你的模型在某些 label 表現得特別好 (可以搭配作業三的 Confusion Matrix)。

答：Lime 方法所呈現的是分數加總比較高的區域，在視覺效果以及易讀性方面，相對於前面兩個方法的表現應該算是比較好的，在這次資料集中，特別是金黃色的區域 (油炸物、蛋黃與考吐司等等) 似乎比較容易有較大的面積被 Lime 方法給選取，比如說下圖右二的蛋皮與右一的炸薯條，兩者各自食物本體部份都是有蠻高的比例被選出來。

但此方法是建立在事先 segment 的結果往下做，所以有時一些重要的 pixels 可能被同個 segment 的其他部份給連累，導致沒有被 Lime 選取，另一方面，原本可能是比較沒用的 pixels 也可能因為其他部份的關係，反而被選出來，比如說下圖左一的照片中，右邊兩個杯子可能因為所佔面積太小，所以在 segment 後被其他部份連累，以至於沒被選出來，左二的桌面與牆面，可能因為在 segment 後與部份食物分到同一塊，而被選出。



4. (3%) [自由發揮] 請同學自行搜尋或參考上課曾提及的內容，實作任一種方式來觀察 CNN 模型的訓練，並說明你的實作方法及呈現 visualization 的結果。

答：這邊嘗試實做的方法為：SmoothGrad 搭配 Guided backprop 來呈現 model 對於某張影像上，有哪些部份比較受 model 注意。


其中 SmoothGrad 是屬於進階版的 saliency map，作法是將一張影像加上高斯分佈的雜訊丟進 model，如同求 saliency map 般，計算影像的 gradient，並重複此次步驟數次，並將多次結果平均即可得到 SmoothGrad image，其假設為重要的 pixel 就算受到一些擾動，他的仍然會擁有一定程度的重要性，而當下重要的 pixel，經過一點點的擾動很可能就不是個重要的 pixel。數學式如下：

$$M_c(x) = \frac{1}{n} \sum_{1}^n M_c(x + \mathcal{N}(0, \sigma^2))$$

Guided backprop 是屬於特製的 back propagation 規則，在一般 back propagation 的進行中，只要當初經過 activation 的輸出不為 0，則就需要將計算的 gradient 值進行更新，而這邊使用的 Guided backprop 是說除了當初經過 activation 的輸出不為 0 之外，往回傳遞的值要是正的才往回傳遞。搭配 ReLU 使用的含意為，一張影像有哪些部份提供 model 能夠判斷正確的重要資訊，某種程度就是濾掉一些對於判斷沒有好影響的部份。

在 SmoothGrad 部份 sigma 設定為 0.2，samle 數設定為：200，Guided backprop 在每層 ReLU 加上back propagate 條件 (> 0 才能夠往回更新)

在視覺呈現方面，可以提供一張影像有正向影響的重要區域，會比 saliency map 更容易了解 model 訓練的成果。下圖中右二的例子就是個蠻明顯的例子，幾乎可以說明蛋糕本身是對於 model 而言，是個要的資訊，而周遭的盤子、桌子等的重要程度就相當低。



c) activation: $f_i^{l+1} = \text{relu}(f_i^l) = \max(f_i^l, 0)$

backpropagation: $R_i^l = (f_i^l > 0) \cdot R_i^{l+1}$, where $R_i^{l+1} = \frac{\partial f_{out}}{\partial f_i^{l+1}}$

backward 'deconvnet': $R_i^l = (R_i^{l+1} > 0) \cdot R_i^{l+1}$

guided backpropagation: $R_i^l = (f_i^l > 0) \cdot (R_i^{l+1} > 0) \cdot R_i^{l+1}$

